



2η Προγραμματιστική Εργασία

-

Αναζήτηση διανυσμάτων με Νευρωνικο LSH (Neural LSH) σε Python

Ονοματεπώνυμο: Παπαθανασίου Ελένη

A.M.: 1115202200135

Ονοματεπώνυμο: Τόντου Αλτάνη-Δάφνη

A.M.: 1115202200288

1 Επιλογή Υπερπαραμέτρων

Η επιλογή των υπερπαραμέτρων για το *Neural LSH* ξεκίνησε από τις προεπιλεγμένες τιμές που δόθηκαν στην εκφώνηση της εργασίας. Στόχος μας ήταν να δημιουργήσουμε ένα ισορροπημένο σύνολο συνδυασμών που να καλύπτουν ένα εύρος συμπεριφορών, χωρίς να αυξάνεται υπερβολικά ο χρόνος εκτέλεσης.

Ως βασικό σημείο αναφοράς ορίσαμε τον ακόλουθο συνδυασμό, ο οποίος αποτελεί ακριβώς τις προεπιλογές:

$knn = 10$, $m = 100$, $imbalance = 0.03$, $kahip_mode = 2$ (*STRONG*), $layers = 3$, $nodes = 64$, $epochs = 10$, $batch_size = 128$, $lr = 0.001$, $seed = 1$.

Αυτός ορίζεται ως ο Συνδυασμός 1 και για *SIFT* και για *MNIST*.

Στη συνέχεια, τροποποιήσαμε επιλεκτικά ομάδες παραμέτρων για να διερευνήσουμε τις εξής περιπτώσεις:

α) Επέκταση της διαμέρισης (m) και αύξηση της ανισορροπίας ($imbalance$)

Σκοπός: Να ελεγχθεί αν μια λεπτότερη διαμέριση του χώρου (μεγαλύτερο m) οδηγεί σε μικρότερα και πιο ομοιόμορφα υποσύνολα υποψηφίων κατά την αναζήτηση, βελτιώνοντας την ταχύτητα και

πώς η επιτρεπόμενη ανισορροπία επηρεάζει την ποιότητα της διαμέρισης από το *KaHIP*.

β) Αύξηση της γειτνίασης στον k - NN γράφο (knn) και του μεγέθους του δικτύου ($nodes, batch_size$)

Σκοπός: Να μελετηθεί εάν ένας πυκνότερος γράφος γειτνίασης παρέχει καλύτερη δομή για τη διαμέριση και αν ένα μεγαλύτερο νευρωνικό δίκτυο έχει την ικανότητα να μάθει πιο ακριβή αντιστοιχίσεις μεταξύ των διανυσμάτων και των ετικετών διαμέρισης.

γ) Παρέμβαση στις παραμέτρους εκπαίδευσης ($epochs, lr$)

Σκοπός: Να αξιολογηθεί εάν μεγαλύτερος χρόνος εκπαίδευσης (περισσότερα $epochs$) σε συνδυασμό με πιο συντηρητικό ρυθμό μάθησης (lr) οδηγεί το μοντέλο σε καλύτερη σύγκλιση και συνεπώς σε υψηλότερη ακρίβεια πρόβλεψης κατά την αναζήτηση.

Στρατηγική Διεξαγωγής Πειραμάτων:

Αλλάζαμε μία ή δύο παραμέτρους ανά πείραμα για να μπορούμε να αποτυπώσουμε ξεκάθαρα τις αλλαγές στην απόδοση. Ταυτόχρονα, αποφύγαμε υπερβολικά μεγάλες τιμές λόγω χρονικών και υπολογιστικών περιορισμών.

2 Αποτελέσματα

Για κάθε συνδυασμό($number$) του πίνακα με τις παραμέτρους μοντέλου τρέχουμε όλους τους συνδυασμούς του πίνακα με τις παραμέτρους δοκιμών. Αυτό ισχύει για την 2η εργασία.

Για την 1η τρέχουμε όλους τους συνδυασμούς που υπάρχουν στα πινακάκια με τις παραμέτρους μοντέλου.

2.1 1ης Εργασίας

<i>Number</i>	<i>Type</i>	<i>k</i>	<i>L</i>	<i>w</i>	<i>N</i>	<i>R</i>	<i>seed</i>	<i>range</i>
1	<i>SIFT</i>	2	40	100.0	1	200	1	<i>true</i>
2	<i>SIFT</i>	3	40	200.0	1	200	1	<i>false</i>
3	<i>SIFT</i>	2	50	100.0	1	300	1	<i>false</i>
4	<i>SIFT</i>	3	30	200.0	1	300	1	<i>true</i>
1	<i>MNIST</i>	2	40	100.0	1	200	1	<i>true</i>
2	<i>MNIST</i>	3	40	200.0	1	200	1	<i>false</i>
3	<i>MNIST</i>	2	50	100.0	1	300	1	<i>false</i>
4	<i>MNIST</i>	3	30	200.0	1	300	1	<i>true</i>

Πίνακας 1: Παράμετροι μοντέλου 1ης Εργασίας *LSH*

<i>Number</i>	<i>Queries</i>	<i>Database</i>	<i>Av.AF</i>	<i>Av.Recall@1</i>	<i>Av.QPS</i>	<i>Av.tApproximate</i>	<i>Av.tTrue</i>
1	10,000	70,000	1.01302	0.7192	7.02627	0.0346302	0.0809682
2	10,000	70,000	1.01028	0.7678	9.36299	0.0200012	0.0865794
3	10,000	70,000	1.00901	0.7871	7.13101	0.0423429	0.0977359
4	10,000	70,000	1.0153	0.6865	5.80774	0.0235443	0.128825
1	10,000	60,000	1	1	0.899592	0.421936	0.283958
2	10,000	60,000	1	1	0.807077	0.916715	0.322167
3	10,000	60,000	1	1	0.285218	2.09273	0.295994
4	10,000	60,000	1	1	1.30123	0.476508	0.29179

Πίνακας 2: Αποτελέσματα αναζήτησης 1ης εργασίας *LSH*

<i>Number</i>	<i>Type</i>	<i>kproj</i>	<i>w</i>	<i>M</i>	<i>probes</i>	<i>N</i>	<i>R</i>	<i>seed</i>	<i>range</i>
1	<i>SIFT</i>	4	50.0	5000	16	1	5000	1	<i>false</i>
2	<i>SIFT</i>	5	50.0	500	5	1	2800	1	<i>false</i>
3	<i>SIFT</i>	2	100.0	10000	4	1	2	1	<i>false</i>
4	<i>SIFT</i>	4	50.0	1000	50	1	2	1	<i>true</i>
1	<i>MNIST</i>	4	50.0	5000	16	1	5000	1	<i>false</i>
2	<i>MNIST</i>	5	50.0	500	5	1	2800	1	<i>false</i>
3	<i>MNIST</i>	2	100.0	10000	4	1	2	1	<i>false</i>
4	<i>MNIST</i>	4	50.0	1000	50	1	2	1	<i>true</i>

Πίνακας 3: Παράμετροι μοντέλου 1ης Εργασίας *Hypercube*

<i>Number</i>	<i>Queries</i>	<i>Database</i>	<i>Av.AF</i>	<i>Av.Recall@1</i>	<i>Av.QPS</i>	<i>Av.tApproximate</i>	<i>Av.tTrue</i>
1	10,000	70,000	1.14251	0.0692	9.09799	0.0077849	0.101996
2	10,000	70,000	1.31472	0.0061	8.27844	0.00090543	0.119747
3	10,000	70,000	1.10769	0.1474	7.02634	0.0181689	0.124005
4	10,000	70,000	1.26435	0.0735	2.39174	0.0063811	0.405389
1	10,000	60,000	1.121	0.2526	2.52001	0.0291552	0.367555
2	10,000	60,000	1.31346	0.0583	1.4982	0.00332928	0.664004
3	10,000	60,000	1.13283	0.1699	2.11243	0.064367	0.408879
4	10,000	60,000	1.26435	0.0735	2.39174	0.00638117	0.405389

Πίνακας 4: Αποτελέσματα αναζήτησης 1ης εργασίας *Hypercube*

<i>Number</i>	<i>Type</i>	<i>kclusters</i>	<i>nprobe</i>	<i>N</i>	<i>R</i>	<i>seed</i>	<i>range</i>
1	<i>SIFT</i>	50	5	1	2800	1	<i>false</i>
2	<i>SIFT</i>	10	2	1	2000	1	<i>false</i>
3	<i>SIFT</i>	50	5	1	2800	1	<i>true</i>
1	<i>MNIST</i>	50	5	1	2800	1	<i>false</i>
2	<i>MNIST</i>	10	2	1	2000	1	<i>false</i>
3	<i>MNIST</i>	50	5	1	2800	1	<i>true</i>

Πίνακας 5: Παράμετροι μοντέλου 1ης Εργασίας *IVFFlat*

<i>Number</i>	<i>Queries</i>	<i>Database</i>	<i>Av.AF</i>	<i>Av.Recall@1</i>	<i>Av.QPS</i>	<i>Av.tApproximate</i>	<i>Av.tTrue</i>
1	10,000	70,000	0.0648002	0.9574	82.713	0.00108277	0.0109085
2	10,000	70,000	0.0684658	0.9661	7.83169	0.0201779	0.10736
3	10,000	70,000	0.0684463	0.9678	6.54045	0.0107528	0.118075
1	10,000	60,000	0.509669	0.9894	2.53843	0.0348438	0.35897
2	10,000	60,000	0.510108	0.9644	2.21446	0.0748401	0.376607
3	10,000	60,000	0.509669	0.9894	2.77422	0.0299903	0.285124

Πίνακας 6: Αποτελέσματα αναζήτησης 1ης εργασίας *IVFFlat*

<i>Number</i>	<i>Type</i>	<i>kclusters</i>	<i>nprobe</i>	<i>nbits</i>	<i>M</i>	<i>N</i>	<i>R</i>	<i>seed</i>	<i>range</i>
1	<i>SIFT</i>	50	5	8	16	1	2800	1	<i>false</i>
2	<i>SIFT</i>	40	5	12	8	1	200	1	<i>false</i>
3	<i>SIFT</i>	50	5	8	16	1	2800	1	<i>true</i>
1	<i>MNIST</i>	50	5	8	16	1	2800	1	<i>false</i>
2	<i>MNIST</i>	40	5	12	8	1	200	1	<i>false</i>
3	<i>MNIST</i>	50	5	8	16	1	2800	1	<i>true</i>

Πίνακας 7: Παράμετροι μοντέλου 1ης Εργασίας *IVFPQ*

<i>Number</i>	<i>Queries</i>	<i>Database</i>	<i>Av.AF</i>	<i>Av.Recall@1</i>	<i>Av.QPS</i>	<i>Av.tApproximate</i>	<i>Av.tTrue</i>
1	10,000	70,000	3.65844	0.4723	78.3087	0.00189887	0.0107866
2	10,000	70,000	3.70210	0.4215	58.4432	0.00210311	0.0112248
3	10,000	70,000	3.79533	0.4532	64.1277	0.00200145	0.0109923
1	10,000	60,000	3.32333	0.3989	1.25378	0.0102039	0.787257
2	10,000	60,000	3.41122	0.3621	1.50437	0.0098873	0.755112
3	10,000	60,000	3.25790	0.4144	1.28455	0.0107112	0.768341

Πίνακας 8: Αποτελέσματα αναζήτησης 1ης εργασίας *IVFPQ*

2.2 2ης Εργασίας

<i>Number</i>	<i>Type</i>	<i>knn</i>	<i>m</i>	<i>imbalance</i>	<i>kahip_mode</i>	<i>layers</i>	<i>nodes</i>	<i>epochs</i>	<i>batch_size</i>	<i>lr</i>	<i>seed</i>
1	<i>SIFT</i>	10	100	0.03	2	3	64	10	128	0.001	1
2	<i>SIFT</i>	10	200	0.05	2	3	64	20	128	0.001	1
3	<i>SIFT</i>	20	100	0.03	2	3	128	10	256	0.001	1
4	<i>SIFT</i>	20	200	0.05	2	3	128	20	256	0.0005	1
5	<i>SIFT</i>	40	100	0.03	2	3	256	10	128	0.0005	1
6	<i>SIFT</i>	40	200	0.05	2	3	256	20	256	0.001	1
1	<i>MNIST</i>	10	100	0.03	2	3	64	10	128	0.001	1
2	<i>MNIST</i>	10	200	0.05	2	3	64	20	128	0.001	1
3	<i>MNIST</i>	20	100	0.03	2	3	128	10	256	0.001	1
4	<i>MNIST</i>	20	200	0.05	2	3	128	20	256	0.0005	1
5	<i>MNIST</i>	40	100	0.03	2	3	256	10	128	0.0005	1
6	<i>MNIST</i>	40	200	0.05	2	3	256	20	256	0.001	1

Πίνακας 9: Παράμετροι μοντέλου 2ης Εργασίας

<i>Number</i>	<i>N</i>	<i>R</i>	<i>T</i>	<i>range</i>
α	1	2.800	5	<i>true</i>
β	1	2.800	5	<i>false</i>
γ	1	2.800	10	<i>true</i>
δ	1	3.000	10	<i>true</i>

Πίνακας 10: Παράμετροι δοκιμών 2ης Εργασίας *SIFT*

<i>Number</i>	<i>N</i>	<i>R</i>	<i>T</i>	<i>range</i>
α	1	2.000	5	<i>true</i>
β	1	2.800	5	<i>false</i>
γ	1	2.000	10	<i>true</i>
δ	1	2.800	10	<i>true</i>

Πίνακας 11: Παράμετροι δοκιμών 2ης Εργασίας *MNIST*

<i>Number</i>	<i>Queries</i>	<i>Database</i>	<i>Av.AF</i>	<i>Av.Recall@1</i>	<i>Av.QPS</i>	<i>Av.tApproximate</i>	<i>Av.tTrue</i>
1 α	10,000	70,000	2.512631	0.132700	31.023837	0.003905	0.030277
1 β	10,000	70,000	1.109939	0.139300	30.769790	0.003667	0.029700
1 γ	10,000	70,000	2.531367	0.241900	24.294826	0.006871	0.036826
1 δ	10,000	70,000	2.531367	0.241900	24.037063	0.007845	0.036784
2 α	10,000	70,000	2.491166	0.094500	29.404042	0.002520	0.033060
2 β	10,000	70,000	1.137007	0.094400	31.768410	0.002203	0.030455
2 γ	10,000	70,000	2.536357	0.258000	27.760615	0.007441	0.039664
2 δ	10,000	70,000	2.505329	0.163200	26.091866	0.004317	0.036197
3 α	10,000	70,000	2.527624	0.156200	30.917565	0.004477	0.031420
3 β	10,000	70,000	1.103775	0.156300	33.080587	0.003409	0.027371
3 γ	10,000	70,000	2.527049	0.250100	27.573972	0.007080	0.030918
3 δ	10,000	70,000	2.527049	0.250100	32.246368	0.005378	0.027318
4 α	10,000	70,000	2.511254	0.105900	38.347264	0.001921	0.025070
4 β	10,000	70,000	1.132344	0.104900	32.421017	0.002273	0.030207
4 γ	10,000	70,000	2.520100	0.174900	36.729043	0.002892	0.025351
4 δ	10,000	70,000	2.520100	0.174900	37.303006	0.002877	0.024872
5 α	10,000	70,000	2.543745	0.164100	35.768467	0.003032	0.026198
5 β	10,000	70,000	1.100920	0.162900	32.453263	0.003115	0.028501
5 γ	10,000	70,000	2.547862	0.267300	28.034338	0.008200	0.030818
5 δ	10,000	70,000	2.547862	0.267300	27.940559	0.006858	0.030619
6 α	10,000	70,000	2.530496	0.109600	33.066191	0.002361	0.0298669
6 β	10,000	70,000	1.132188	0.109200	31.621035	0.002306	0.030511
6 γ	10,000	70,000	2.535371	0.181700	36.808974	0.002881	0.025290
6 δ	10,000	70,000	2.535371	0.181700	36.180046	0.003083	0.026334

Πίνακας 12: Αποτελέσματα αναζήτησης 2ης εργασίας *SIFT*

<i>Number</i>	<i>Queries</i>	<i>Database</i>	<i>Av.AF</i>	<i>Av.Recall@1</i>	<i>Av.QPS</i>	<i>Av.tApproximate</i>	<i>Av.tTrue</i>
1 α	10,000	60.000	2.697205	0.105900	9.225620	0.009006	0.104608
1 β	10,000	60.000	1.171726	0.105900	6.616364	0.010186	0.147680
1 γ	10,000	60.000	2.700603	0.194000	7.808495	0.019969	0.116700
1 δ	10,000	60.000	2.700603	0.194000	8.165937	0.019329	0.110156
2 α	10,000	60.000	2.695438	0.072300	9.343074	0.003833	0.107825
2 β	10,000	60.000	1.215777	0.072300	7.699599	0.005427	0.129686
2 γ	10,000	60.000	2.697153	0.128000	9.471471	0.008063	0.102267
2 δ	10,000	60.000	2.697153	0.128000	9.526700	0.008101	0.101447
3 α	10,000	60.000	2.700090	0.118100	9.435607	0.165747	0.101834
3 β	10,000	60.000	1.167452	0.118100	7.039774	0.010740	0.138295
3 γ	10,000	60.000	2.702885	0.204200	8.716726	0.017974	0.102653
3 δ	10,000	60.000	2.702885	0.204200	8.706467	0.018046	0.102603
4 α	10,000	60.000	2.687512	0.082800	8.714214	0.004488	0.119097
4 β	10,000	60.000	1.201122	0.081300	6.989727	0.006341	0.142876
4 γ	10,000	60.000	2.691718	0.143900	8.705514	0.007828	0.117814
4 δ	10,000	60.000	2.691718	0.143900	8.235679	0.018629	0.123063
5 α	10,000	60.000	2.699317	0.130100	7.444023	0.009414	0.133722
5 β	10,000	60.000	1.157971	0.129300	6.938875	0.010994	0.139526
5 γ	10,000	60.000	2.702049	0.221600	7.555196	0.015926	0.123433
5 δ	10,000	60.000	2.702049	0.221600	6.751421	0.019547	0.498928
6 α	10,000	60.000	2.694098	0.119700	7.682217	0.004647	0.133487
6 β	10,000	60.000	1.177911	0.115200	7.213881	0.005823	0.140285
6 γ	10,000	60.000	2.696459	0.192600	7.430167	0.008188	0.135268
6 δ	10,000	60.000	2.696459	0.192600	7.392773	0.008236	0.133179

Πίνακας 13: Αποτελέσματα αναζήτησης 2ης εργασίας *MNIST*

3 Ερμηνεία Αποτελεσμάτων

Μέθοδος	<i>Recall@</i>	<i>QPS</i>	<i>AF</i>	<i>ApproxTime</i>	<i>TrueTime</i>	Μέγεθος <i>Dataset</i>
<i>NeuralLSH</i>	0.07 – 0.26	6 - 38	1.10 - 2.7	0.0022 - 0.16	0.025 - 0.5	70K
<i>LSH</i>	0.68 - 1	0.28 - 9.4	1 - 1.01	0.02 - 2.1	0.08 - 0.32	70K
<i>Hypercube</i>	0.006 - 0.25	1.5 - 9	1.10 - 1.314	0.0009 - 0.65	0.10 - 0.66	70K
<i>IVFPQ</i>	0.36 - 0.47	1.25 - 78.3	3.25 - 3.79	0.0018 - 0.01	0.010 - 0.78	70K
<i>IVFFlat</i>	0.95 - 0.98	2.21 - 82.7	0.064 - 0.51	0.001 - 0.07	0.01 - 0.37	70K

Πίνακας 14: Διαστήματα αποτελεσμάτων MNIST + SIFT

3.1 Συγκριτική Ανάλυση Αποτελεσμάτων 1ης και 2ης Εργασίας

3.1.1 Ερμηνεία Αποτελεσμάτων 1ης Εργασίας

Η ερμηνεία βαζίζεται στα 70K *vectors* που παίρνουμε αντί για 1M.

Στην πρώτη εργασία αξιολογήθηκαν οι μέθοδοι *LSH*, *Hypercube*, *IVFFlat* και *IVFPQ* στα *datasets SIFT* και *MNIST*. Τα αποτελέσματα παρουσιάζουν σημαντικές διαφοροποιήσεις τόσο ως προς την ακρίβεια (*Recall@*) όσο και ως προς την ταχύτητα (*QPS*) και την ποιότητα προσέγγισης (*AF*).

Για τον αλγόριθμο *LSH* παρατηρείται μέτριο *Recall* στο *SIFT* (0.68–0.8), σε συνδυασμό με καλό *AF* (1.01) και ικανοποιητικό *QPS* (7–9). Αντίθετα, στο *MNIST* το *Recall* είναι ίσο με 1, όμως η ταχύτητα είναι σημαντικά μειωμένη σε σχέση με το *SIFT*.

Ο *Hypercube* εμφανίζει πολύ χαμηλό *Recall* στο *SIFT* (0.006–0.147) καθώς και χαμηλές τιμές στο *MNIST* (0.05–0.25). Παρ' όλα αυτά, παρουσιάζει υψηλό *QPS* (7–9 στο *SIFT*), γεγονός που τον καθιστά γρήγορο αλλά αναποτελεσματικό από πλευράς ανάκτησης.

Ο αλγόριθμος *IVFFlat* είναι καθαρά ο πιο αποδοτικός: υψηλό *Recall* τόσο στο *SIFT* (0.95–0.97) όσο και στο *MNIST* (0.96–0.99), πολύ χαμηλό *AF* (0.06 στο *SIFT*) και εξαιρετική ταχύτητα, ειδικά για *SIFT* (*QPS* έως 82).

Αντίθετα, το *IVFPQ* παρουσιάζει μέτρια ακρίβεια (*Recall* 0.47 στο *SIFT*) και υψηλό *AF* (3.66), γεγονός που δείχνει χειρότερη συμπεριφορά έναντι του *IVFFlat*.

3.1.2 Ερμηνεία Αποτελεσμάτων 2ης Εργασίας

Στη δεύτερη εργασία εξετάστηκε ένα μοντέλο για την αναζήτηση γειτόνων με νευρωνικό δίκτυο. Οι μετρήσεις παρουσιάζονται για πολλαπλές παραλλαγές παραμέτρων (α – δ).

Το *Recall@* κυμαίνεται στο *SIFT* μεταξύ 0.09–0.26 και στο *MNIST* μεταξύ 0.07–0.22, εμφανώς χαμηλότερο από το *IVFFlat* της πρώτης εργασίας. Παράλληλα, το *AF* βρίσκεται γύρω από το 2.5 για τις περισσότερες παραλλαγές, με τις εκδόσεις β να εμφανίζουν σαφώς καλύτερη ποιότητα προσέγγισης (*AF* 1.10–1.17).

Ως προς την ταχύτητα, το μοντέλο αποδίδει αρκετά καλά: στο *SIFT* το *QPS* φτάνει 24–38, ενώ στο *MNIST* 6–9. Ο προσεγγιστικός χρόνος παραμένει χαμηλός για όλες τις παραλλαγές (0.002–0.02s), σημαντικά καλύτερος από τους προσεγγιστικούς χρόνους της πρώτης εργασίας στο *MNIST*.

3.1.3 Σύγκριση 1ης και 2ης Εργασίας

Συγκρίνοντας άμεσα τις δύο εργασίες με βάση τους πίνακες αποτελεσμάτων, προκύπτουν τα εξής:

Ακρίβεια ($Recall@$). Η πρώτη εργασία υπερέχει ξεκάθαρα. Ο *IVFFlat* επιτυγχάνει *Recall* έως 0.99 στο *MNIST* και 0.97 στο *SIFT*, ενώ στη δεύτερη εργασία δεν ξεπερνά το 0.26 στο *SIFT* και το 0.22 στο *MNIST*. Επομένως, ως προς την ανάκτηση, οι μέθοδοι της πρώτης εργασίας είναι σαφώς πιο αποτελεσματικές.

Ποιότητα Προσέγγισης (AF). Το AF του *IVFFlat* στην πρώτη εργασία είναι εξαιρετικό (0.06–0.5), ενώ οι τιμές *LSH/Hypercube* βρίσκονται κοντά στο 1.1–1.3. Η δεύτερη εργασία εμφανίζει AF περίπου 2.5 για τις περισσότερες παραλλαγές, με εξαίρεση τις εκδόσεις β όπου το AF βρίσκεται στο 1.10–1.17, παρόμοιο δηλαδή με *LSH/Hypercube* της πρώτης εργασίας. Ωστόσο, καμία παραλλαγή δεν πλησιάζει την απόδοση του *IVFFlat*.

Ταχύτητα (QPS). Για *SIFT*, ο *IVFFlat* και ο *Hypercube* της πρώτης εργασίας είναι ταχύτεροι (έως 82 QPS), όμως η δεύτερη εργασία παραμένει ανταγωνιστική (24–38 QPS). Για *MNIST*, η δεύτερη εργασία είναι ταχύτερη από τις αντίστοιχες μεθόδους *LSH/Hypercube* της πρώτης (6–9 QPS έναντι 1).

Χρόνος Αναζήτησης. Η δεύτερη εργασία προσφέρει ιδιαίτερα χαμηλούς προσεγγιστικούς χρόνους (0.002–0.02s), ειδικά στο *MNIST*, όπου είναι σημαντικά μικρότεροι σε σχέση με την πρώτη εργασία. Στο *SIFT* είναι συγκρίσιμο ή ελαφρώς ταχύτερο από *IVFFlat*.

3.1.4 Συνολικό Συμπέρασμα

Η πρώτη εργασία παρουσιάζει καλύτερη ακρίβεια, χάρη κυρίως στον *IVFFlat*. Η δεύτερη εργασία, παρότι υστερεί σε *Recall* και AF , προσφέρει σταθερή και ταχεία αναζήτηση με πολύ χαμηλούς χρόνους ανά ερώτημα. Οι παραλλαγές β πλησιάζουν την ποιότητα προσέγγισης των μεθόδων *LSH/Hypercube* της πρώτης εργασίας, αλλά συνολικά καμία παραλλαγή δεν προσεγγίζει την απόδοση του *IVFFlat*, ο οποίος παραμένει η πιο αποτελεσματική μέθοδος ανάκτησης.